第三讲：注意力机制

梯度下降在每一步沿着负梯度方向更新参数，学习率决定步长。如果学习率太大，损失会来回振荡，甚至发散；如果太小，训练会非常缓慢。这一段话故意写得比较长，用来测试换行时不要在两个汉字之间插入空格，也测试标点符号是否保持全角。

缩放点积注意力把查询和键的点积除以键维度的平方根，然后再做 softmax。Mixed English words like attention and softmax appear here too.